

OpenAI Platform

Tokenizador

Aprenda sobre tokenização de modelos de linguagem

Os grandes modelos de linguagem da OpenAI processam texto usando **tokens**, que são sequências comuns de caracteres encontradas em um conjunto de texto. Os modelos aprendem a entender as relações estatísticas entre esses tokens e se destacam na produção do próximo token em uma sequência. [Saber mais](#).

Você pode usar a ferramenta abaixo para entender como um trecho de texto pode ser tokenizado por um modelo de linguagem e a contagem total de tokens nesse trecho de texto.

GPT-5.x e O1/3

GPT-4 e GPT-3.5 (legado)

GPT-3 (legado)

Maurício Cunha Ortiga Ferreira
A engenharia de prompt otimiza LLMs

Claro

Mostrar exemplo

Fichas

18

Personagens

67

MaurícioCuhaOuigaF

UMFerreiraigaigaFerreiraFerreira LLMs

Texto

IDs de token

Uma regra prática útil é que um token geralmente corresponde a cerca de 4 caracteres de texto em inglês comum. Isso se traduz em aproximadamente $\frac{3}{4}$ de uma palavra (portanto, 100

tokens são aproximadamente 75 palavras).

Se você precisa de uma interface programática para tokenizar texto, confira nossa solução. [token do tiktoken](#) pacote para Python. Para JavaScript, o pacote com suporte da comunidade. [@dbdq/tiktoken](#) O pacote funciona com a maioria dos modelos GPT.