

GUIA DE ESTUDOS A1: Criação de Agentes de IA e Ética Aplicada

**Síntese da Unidade 4: Arquitetura, Privacidade, Viés
e Responsabilidade Social.**

Material Orientativo para Estudantes - UDF

O Roteiro da Nossa Viagem (Metas para a A1)



Fundamentos Técnicos

Do prompt estático
aos Agentes Autônomos
de 4 camadas.

Gestão e Dinâmica

Memória, adaptação
de contexto e
controle de fluxo.

Riscos e Defesas

Privacidade by
design, detecção e
mitigação de vieses.

Ética Aplicada

Frameworks de
decisão e licença
social para operar.


Lembre-se: O modelo acadêmico exige protagonismo. Você deve ser capaz não apenas de definir conceitos, mas de aplicá-los e avaliá-los criticamente.

A Evolução: Modelos Generativos vs. Agentes de IA

Modelos Generativos	Agentes de IA
✗ Ação: Respondem a prompts isolados.	✓ Ação: Atuam no mundo e tomam decisões.
✗ Foco: Geração de texto/conteúdo.	✓ Foco: Ação coordenada e propositiva.
✗ Contexto: Estático (sem memória contínua).	✓ Contexto: Mantêm contexto histórico e aprendem com a interação.
✗ Autonomia: Nenhuma.	✓ Autonomia: Alta (exige maior responsabilidade ética).

“A engenharia de agentes representa a evolução natural da engenharia de prompt... expandindo-se para a ação coordenada.” — Carraro (2023)

A Arquitetura de um Agente (As 4 Camadas)



Alert Box: O Princípio da Interpretabilidade: A confiança depende da capacidade de explicar por que o agente tomou a decisão. Sem transparência, criamos caixas pretas inaceitáveis. (Murta, 2023)

Engenharia de Prompt: Do Estático ao Dinâmico

Prompts para agentes são templates parametrizados que se adaptam em tempo real.

Você é um especialista em
[CATEGORIA_PRODUTO].
O cliente visitou
[PÁGINAS_ANTERIORES] e tem o perfil
[TIPO_CLIENTE].
Baseie-se apenas em [DATA_LIMITE].
Ofereça alternativas via
[CRITÉRIO_RECOMENDAÇÃO].

Insight Chave

O segredo é equilibrar
Arquiteturas Rígidas
(controle, segurança e
regras operacionais)
com **Prompts**
Prompts Flexíveis
(adaptabilidade e
coerência
conversacional).
(Mello, 2024)

Gestão de Memória e Continuidade



Memória Curta

Retém apenas as últimas trocas.

Propósito: Manter a coerência imediata da conversa atual.



Memória Média

Agrupa conversas recentes em resumos.

Propósito: Lembrar do contexto da sessão sem sobrecarregar o processamento.



Memória Longa

Armazena padrões e preferências.

Propósito: Criar perfis duradouros (ex: cliente prefere marcas sustentáveis).

Atenção A1: Mais memória = Melhor contexto, mas também = Maior risco de privacidade.

Privacidade de Dados: Princípio de Arquitetura

A proteção deve nascer no design, não ser um remendo opcional (Lee, Goldberg e Kohane, 2024).



Coleta Mínima (Minimização) -
Solicitar apenas os dados estritamente
necessários para a função.

Criptografia -
Proteção dos dados tanto em
repouso quanto em trânsito.

**Controle de Acesso
Granular** - Restringir
quem (ou o que) pode
acessar informações
sensíveis.

O Dilema do Uso Secundário: Se o agente usa conversas antigas para aprender uma nova habilidade (ex: suporte técnico virar pesquisa médica), a LGPD exige um novo consentimento explícito.

A Anatomia do Viés Algorítmico

O viés não é um bug acidental, é a reprodução lógica de ambientes historicamente injustos (Barcaui, 2025).

Viés de Dados

Dados de treino não representam a população real. (Ex: Chatbot treinado só com lingu. urbana falha com dialetos regionais).

Viés de Algoritmo

Falhas nas escolhas de design, variáveis consideradas ou pesos matemáticos definidos pelo desenvolvedor.

Viés de Aplicação

Usar um modelo treinado para o contexto X em um cenário Y totalmente diferente sem a devida adaptação.

Case Study

Lembre-se do caso da Amazon (2015): o algoritmo de recrutamento eliminava candidatas mulheres pois o sistema otimizou perfeitamente um histórico injusto.

Mitigação e o Custo da Equidade

IA sem auditoria de viés é IA sem responsabilidade.
— Eysenck & Eysenck (2023)

Eficiência Técnica

Estratégias de Mitigação:

- Realizar auditorias de equidade regulares.
- Diversificar a equipe de engenharia.
- Monitorar variáveis correlacionadas (proxies).

Justiça Social

O Dilema Ético:

- Remover variáveis demográficas não resolve o problema estrutural.
- A solução justa muitas vezes exige examinar o contexto social, mesmo sacrificando a eficiência imediata.

Avaliação Crítica: Além das Métricas Tradicionais

Acurácia e latência são insuficientes para agentes de impacto social (Mello, 2024).

Confiança



O usuário sente que é tratado de forma justa?

Robustez



Como o sistema lida com cenários fora do treinamento?

Impacto



Qual o efeito real na vida das pessoas? (Aprovar 99% gera endividamento).

Painel de Testes

- Testes Adversariais:** Tentar fazer o agente falhar intencionalmente (ex: abusos verbais, burlar restrições).
- Testes de Stress:** Avaliar o comportamento sob condições extremas de carga e latência.

O Ciclo de Melhoria Contínua (Feedback Loop)



Frameworks de Decisão Ética


Como escolher quando todos os caminhos possuem trade-offs? (Córdova, 2025).



A ética não é um *checklist* técnico, mas um processo contínuo de resolução de tensões entre esses três pilares.

Responsabilidade Social e Licença de Operação

Sistemas autônomos precisam de mais do que código limpo; precisam de uma Licença Social para Operar (Córdova, 2025).



Checklist de Preparação para a Avaliação A1

- ✓ 1. Sei diferenciar um Modelo Generativo de um Agente Autônomo?
- ✓ 2. Consigo mapear as 4 camadas de arquitetura de um agente?
- ✓ 3. Entendo as 3 dimensões da gestão de memória e seus riscos de privacidade?
- ✓ 4. Sei identificar vieses (Dados, Algoritmo, Aplicação) e propor mitigações?
- ✓ 5. Consigo aplicar os frameworks éticos a um estudo de caso real?

**A tecnologia que construímos molda a sociedade que habitamos. O protagonismo agora é seu.
Bons estudos e excelente A1!**

